Corpora di apprendenti di italiano L2 second edition

Ciao! Mi presento



Arianna Bienati

PhD fellow in Reggio Childhood Studies. Applied linguist @EuracLing. Fascinated by all things quantitative. Per il resto, faccio cose, vedo gente.

Che cosa faremo oggi e domani?

Alla scoperta dei learner corpora Usare i learner corpora

Insegnare con i (learner) corpora

Alla scoperta dei learner corpora... ... momento varietà

Che cos'è un corpus?

Alla scoperta dei learner corpora... ... momento varietà

Che cos'è un corpus?

Quali corpora conosci/hai usato?

Conosci/hai usato qualche corpus di apprendenti?

Conosci/hai usato qualche corpus di apprendenti di italiano L2/LS?



Collaboriamo insieme su questo Google doc:

https://tinyurl.com/learnercorporabolo2025

Un po' di storia

Gli strumenti

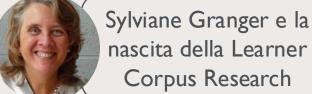
L'output scientifico e didattico



La community di Learner Corpus Research







La ricerca scientifica e le applicazioni didattiche



Che cosa si può fare con i corpora di apprendenti?



Contrastive Interlanguage Analysis (CIA 2.0)

- Paragone tra le produzioni di apprendenti e nativi
- Paragone tra le produzioni di apprendenti con diverse LI

Es. Granger, 2015; Corino & Marello, 2017

Sequenze acquisizionali

 Paragone tra apprendenti con competenze linguistiche diverse e focus su uno specifico livello linguistico/fenomeno linguistico

Es. Giacalone Ramat, 2003

Annotazione dei corpora con target hypothesis (TH)

- Analisi analitica di fenomeni specifici dell'interlingua
- Informazioni utili per la pratica didattica



Che cosa si può fare con i corpora di apprendenti?



Contrastive Interlanguage Analysis (CIA 2.0)

- Paragone tra le produzioni di apprendenti e nativi
- Paragone tra le produzioni di apprendenti con diverse L1

Es. Granger, 2015; Corino & Marello, 2017

Sequenze acquisizionali

 Paragone tra apprendenti con competenze linguistiche diverse e focus su uno specifico livello linguistico/fenomeno linguistico

Es. Giacalone Ramat, 2003

Annotazione dei corpora con target hypothesis (TH)

- Analisi analitica di fenomeni specifici dell'interlingua
- Informazioni utili per la pratica didattica



Che cosa si può fare con i corpora di apprendenti?



Contrastive Interlanguage Analysis (CIA 2.0)

- Paragone tra le produzioni di apprendenti e nativi
- Paragone tra le produzioni di apprendenti con diverse LI

Es. Granger, 2015; Corino & Marello, 2017

Sequenze acquisizionali

 Paragone tra apprendenti con competenze linguistiche diverse e focus su uno specifico livello linguistico/fenomeno linguistico

Es. Giacalone Ramat, 2003

Annotazione dei corpora con target hypothesis (TH)

- Analisi analitica di fenomeni specifici dell'interlingua
- Informazioni utili per la pratica didattica



Che cosa si può fare con i corpora di apprendenti?



Contrastive Interlanguage Analysis (CIA 2.0)

- Paragone tra le produzioni di apprendenti e nativi
- Paragone tra le produzioni di apprendenti con diverse L1

Es. Granger, 2015; Corino & Marello, 2017

Sequenze acquisizionali

 Paragone tra apprendenti con competenze linguistiche diverse e focus su uno specifico livello linguistico/fenomeno linguistico

Es. Giacalone Ramat, 2003

Annotazione dei corpora con target hypothesis (TH)

- Analisi analitica di fenomeni specifici dell'interlingua
- Informazioni utili per la pratica didattica



Che cosa si può fare con i corpora di apprendenti?



Contrastive Interlanguage Analysis (CIA 2.0)

- Paragone tra le produzioni di apprendenti e nativi
- Paragone tra le produzioni di apprendenti con diverse L1

Es. Granger, 2015; Corino & Marello, 2017

Sequenze acquisizionali

 Paragone tra apprendenti con competenze linguistiche diverse e focus su uno specifico livello linguistico/fenomeno linguistico

Es. Giacalone Ramat, 2003

Annotazione dei corpora con target hypothesis (TH)

- Analisi analitica di fenomeni specifici dell'interlingua
- Informazioni utili per la pratica didattica





Alla scoperta dei *learner corpora*... secondo momento varietà

Scegli un corpus tra quelli elencati in tabella e trova le seguenti informazioni:

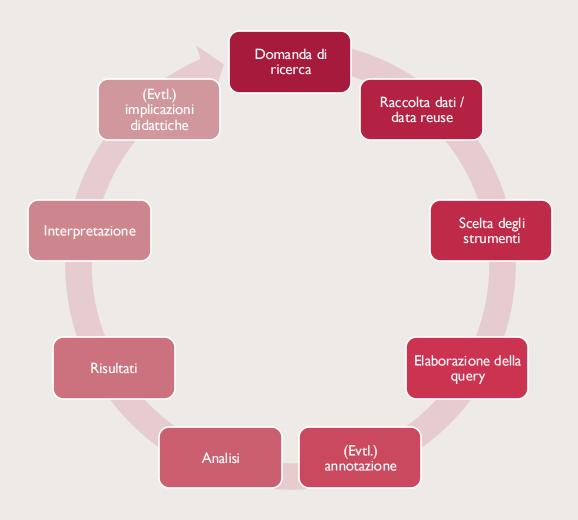
- possibilità di consultazione: sì/no; tramite interfaccia e/o download; link
- modalità: scritta, orale, entrambe
- metadati: sui partecipanti (es. età, genere, LI, istruzione, etc.); sul tipo di task (es. prompt, tipo/genere testuale, etc.)
- annotazioni linguistiche: lemma, pos, dependency, target hypothesis, altre annotazioni specifiche?



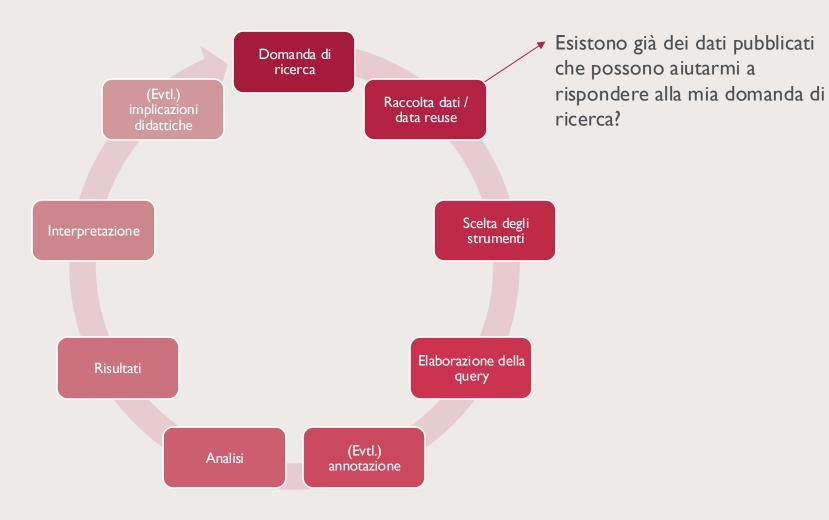
Collaboriamo insieme su questo Google doc:

https://tinyurl.com/learnercorporabolo2025

Un possibile lifecycle di una ricerca / ricerca-azione con i learner corpora



Un possibile lifecycle di una ricerca / ricerca-azione con i learner corpora



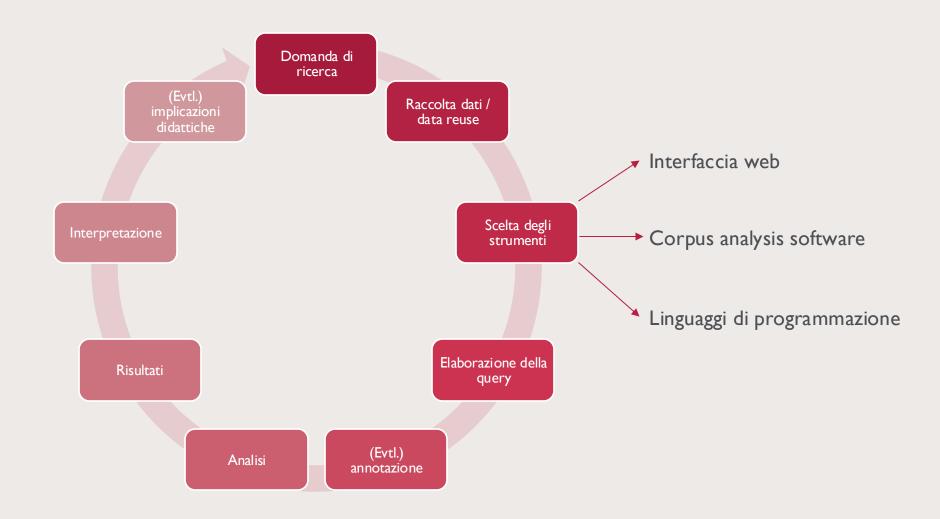
Raccolta dati & data re-use: che cos'è CLARIN e perché mi dovrebbe importare?



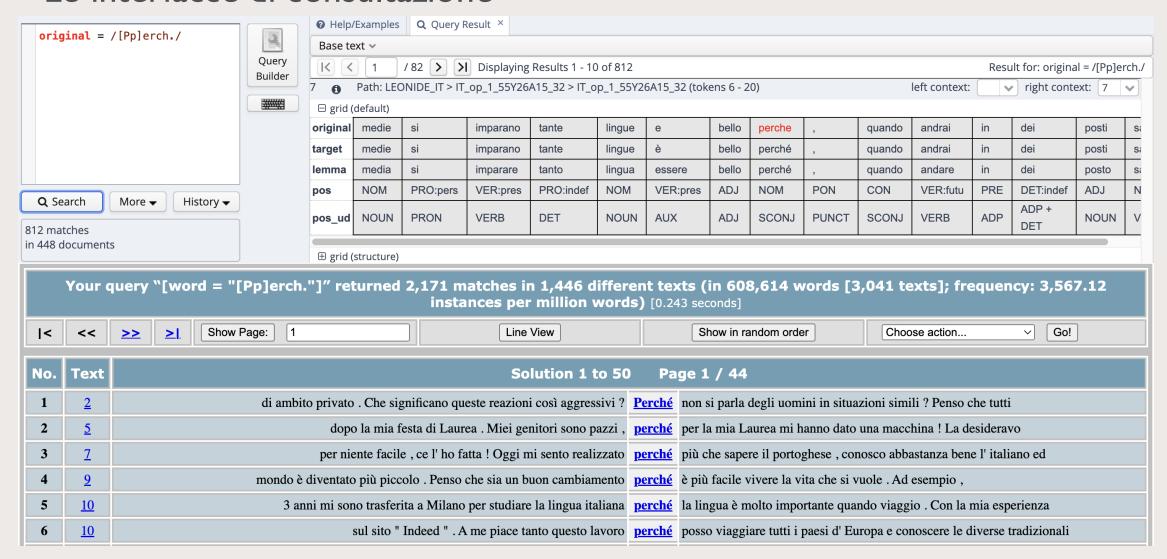
Su CLARIN puoi...

- trovare dati utili per la tua ricerca
 - documentati
 - scaricabili
 - (spesso) interoperabili
 - con chiare indicazioni su cosa puoi fare con quei dati (licenze)
- depositare i tuoi dati di ricerca
 - altri ricercatori li possono trovare (e citare)...
 - ... potenzialmente per sempre

Gli strumenti

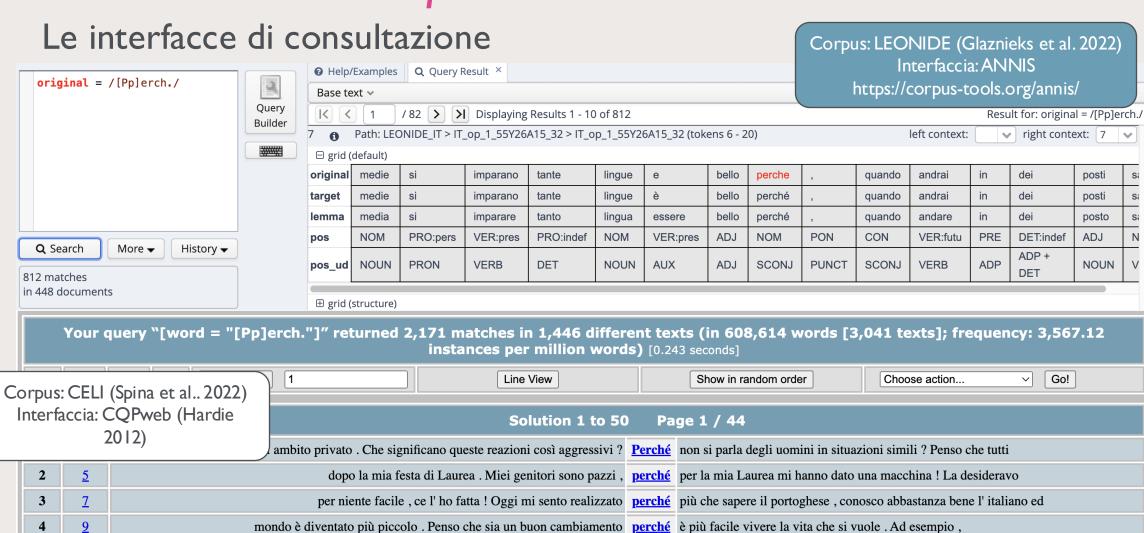


Le interfacce di consultazione



10

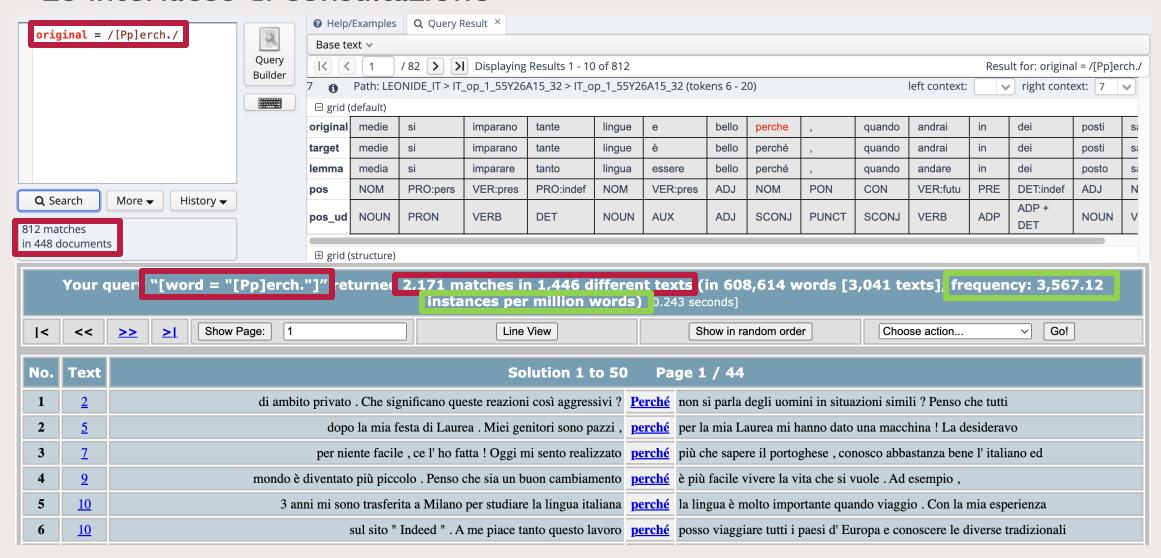
<u>10</u>



3 anni mi sono trasferita a Milano per studiare la lingua italiana perché la lingua è molto importante quando viaggio. Con la mia esperienza

sul sito " Indeed " . A me piace tanto questo lavoro perché posso viaggiare tutti i paesi d' Europa e conoscere le diverse tradizionali

Le interfacce di consultazione



costruzione di un sillabo data-driven

Immagina di essere un/a docente di italiano L2 a cui è stato affidato il compito di costruire un sillabo, dal livello B1 al livello C2 del CEFR, relativamente all'uso di parole connettive nello scritto.

- Scelta del corpus: quale corpus posso usare? Quali corpora hanno le caratteristiche che mi servono (metadati: livello CEFR)?
- Costruzione della query: come posso cercare i connettivi? Su cosa mi concentro (congiunzioni subordinanti, avverbi, etc.)?
- Query ristretta: come faccio a restringere la query su ciascuno dei livelli che mi interessano?



Collaboriamo insieme su questo Google doc:

https://tinyurl.com/learnercorporabolo2025

Pensa alle tue esperienze di insegnamento di una L2/LS:

- Hai mai usato corpora per preparare le lezioni?
- Hai mai usato corpora in classe?

Pensa alle tue esperienze di apprendimento di una L2/LS:

• I tuoi docenti hanno mai usato corpora in classe?



Collaboriamo insieme su questo Google doc:

https://tinyurl.com/learnercorporabolo2024

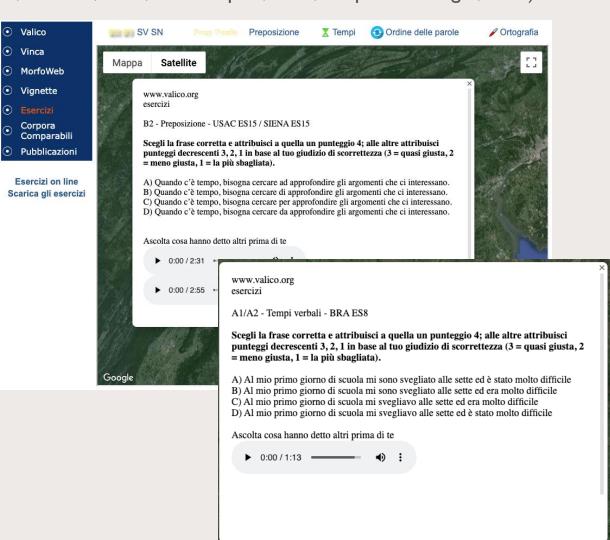
Usi diretti e indiretti (Leech, 1998; Granger, 2009; Meunier, 2010; Forti e Spina, 2019; Gilquin e Granger, 2022)

Usi indiretti

- Lessicografia (es. Longman Dictionary of Contemporary English; Cambridge Advanced Learner's Dictionary)
- Creazione del sillabo e dei materiali all'interno del sillabo
 - Esercizi
 - Task

Es. per l'italiano: Corino e Marello (2009): esercizi a scelta multipla, basati sugli errori di apprendenti francofoni, ispanofoni, lusofoni e anglofoni.

puoi esplorare gli esercizi proposti e il corpus sul sito: http://www.valico.org/

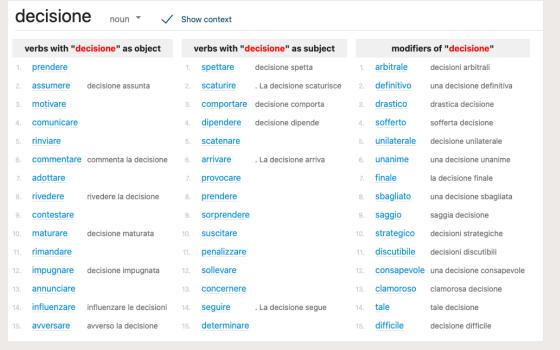


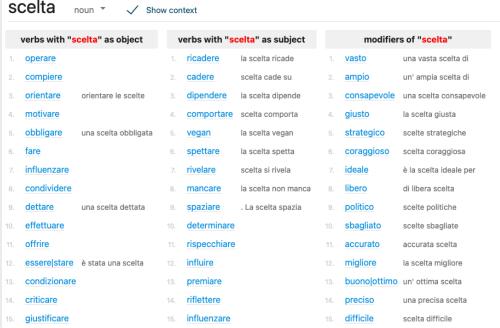
Usi diretti e indiretti (Leech, 1997; Granger, 2009; Meunier, 2010; Forti e Spina, 2019; Gilquin e Granger, 2022)

Usi diretti

"Direct uses aim to make corpus data immediately visible to the learners, so that they can explore it and use it within learning activities" (Forti e Spina, 2019).

→ Es. SkELL (Sketch Engine for Language Learning). Easy to use, interfaccia user-friendly.

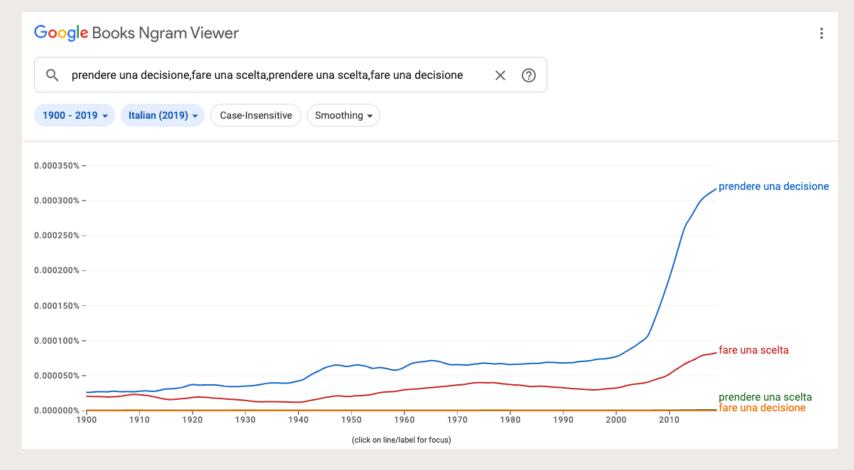




Usi diretti e indiretti (Leech, 1997; Granger, 2009; Meunier, 2010; Forti e Spina, 2019; Gilquin e Granger, 2022)

Usi diretti

→ Es. Google Ngram Viewer: Easy to use, interfaccia user-friendly.



Esercitazione di data-driven learning

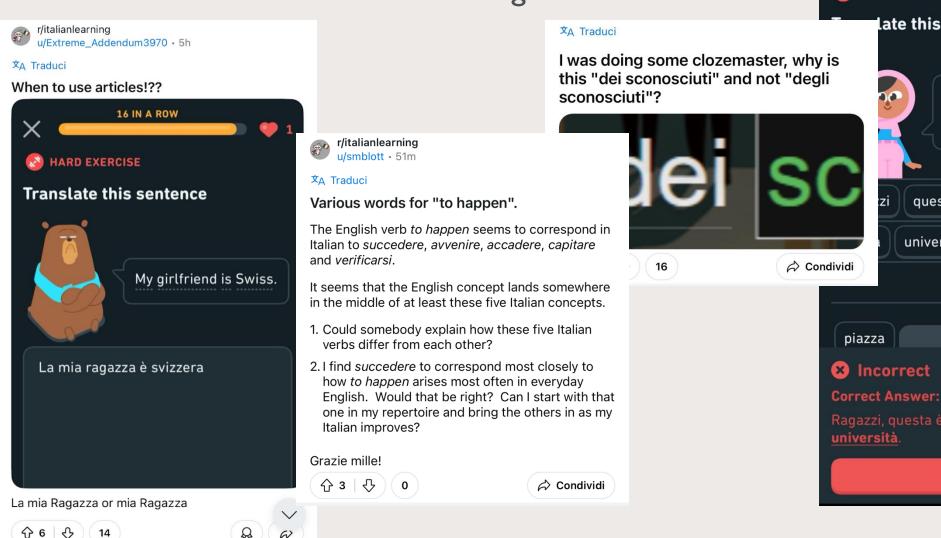
Come possiamo guidare la risoluzione di dubbi linguistici degli apprendenti tramite l'uso dei corpora?



Collaboriamo insieme su questo Google doc:

https://tinyurl.com/learnercorporabolo2025

Esercitazione di data-driven learning



A HARD EXERCISE

late this sentence

questa

università

Guys, this is your

new university.

è

rosse

GOT IT

la

le vostre

⁽¹⁾ ᇯ

nuova

Conclusioni: perché?

Perché sbattersi per usare i corpora nell'era dell'Al (generativa)?

Quali i pro e quali i contro?

Bibliografia

- Andorno, Cecilia, Ada Valentini, e Roberta Grassi. 2017. Verso una nuova lingua: capire l'acquisizione di L2. Milano: UTET università. Biber, Douglas, e Susan Conrad. 2009. Register, Genre, and Style. Cambridge Textbooks in Linguistics. Cambridge: Cambridge University Press. https://doi.org/10.1017/CBO9780511814358.
- Bienati, Arianna, e Jennifer-Carmen Frey. 2024. «Development of causal connectives in Italian L1 and L2 student writing: A comparison of argumentative texts from lower and upper secondary school.» In Continuing Learner Corpus Research: Challenges and Opportunities. Louvain: Presses Universitaires de Louvain.
- Boyd, Adriane, Jirka Hana, Lionel Nicolas, Detmar Meurers, Katrin Wisniewski, Andrea Abel, Karin Schöne, Barbora Štindlová, e Chiara Vettori. 2014. «The MERLIN corpus: Learner language and the CEFR». In *Proceedings of the Ninth International Conference on Language Resources and Evaluation (LREC'14)*, a cura di Nicoletta Calzolari, Khalid Choukri, Thierry Declerck, Hrafn Loftsson, Bente Maegaard, Joseph Mariani, Asuncion Moreno, Jan Odijk, e Stelios Piperidis, I 281–88. Reykjavik, Iceland: European Language Resources Association (ELRA). http://www.lrec-conf.org/proceedings/lrec2014/pdf/606_Paper.pdf.
- Corino, Elisa, e Carla Marello. 2009. «Didattica con i corpora di italiano per stranieri.» *Italiano LinguaDue* 1 (1): 279–279. https://doi.org/10.13130/2037-3597/444.
- Durrant, Philip, e Ayça Durrant. 2022. «Appropriateness as an aspect of lexical richness: What do quantitative measures tell us about children's writing?» Assessing Writing 51 (gennaio): 100596. https://doi.org/10.1016/j.asw.2021.100596.
- Forti, Luciana, e Stefania Spina. 2020. «Corpora for linguists vs. Corpora for learners bridging the gap in italian L2 learning and teaching». 8 | 2 | 2019, fasc. 2 (aprile). https://doi.org/10.30687/elle/2280-6792/2019/02/005.
- Giacalone Ramat, Anna. 2003. Verso l'italiano. Percorsi e strategie di acquisizione. Roma: Carocci.
- Gilquin, Gaëtanelle, e Sylviane Granger. 2022. «Using data-driven learning in language teaching». In , 430–42.
- Glaznieks, Aivars, Jennifer-Carmen Frey, Maria Stopfner, Lorenzo Zanasi, e Lionel Nicolas. 2022. «Leonide: A Longitudinal Trilingual Corpus of Young Learners of Italian, German and English». *International Journal of Learner Corpus Research* 8 (1): 97–120. https://doi.org/10.1075/ijlcr.21004.gla.
- Granger, Sylviane. 2009. «The contribution of learner corpora to second language acquisition and foreign language teaching: A critical evaluation». In *Corpora and Language Teaching*, I 3–32. https://doi.org/10.1075/scl.33.04gra.

Bibliografia

- Granger, Sylviane. 2015. «Contrastive Interlanguage Analysis: A Reappraisal». *International Journal of Learner Corpus Research* 1 (1): 7–24. https://doi.org/10.1075/ijlcr.1.1.01gra.
- Hardie, Andrew. 2013. «CQPweb Combining Power, Flexibility and Usability in a Corpus Analysis Tool». *International Journal of Corpus Linguistics* 17 (3): 380–409. https://doi.org/10.1075/ijcl.17.3.04har.
- Konecny, C, Andrea Abel, E Autelli, e Lorenzo Zanasi. 2016. «Identification and Classification of Phrasemes in an L2 Learner Corpus of Italian». In Computerised and Corpus-Based Approaches to Phraseology: Monolingual and Multilingual Perspectives = Fraseología Computacional y Basada En Corpus: Perspectivas Monolingües y Multilingües, 533–42. GenevaDA 2016///: Tradulex.
- Leech, Geoffrey. 1998. «Teaching and Language Corpora: a Convergence». In Teaching and Language Corpora. Routledge.
- Meunier, Fanny. 2010. «Learner Corpora and English Language Teaching: Checkup Time». Anglistik: International Journal of English Studies 21 (1): 209–20.
- Santipolo, Matteo. 2014. «L'impiego dei materiali autentici per lo sviluppo della competenza sociolinguistica: riflessioni teoriche e spunti operativi». Cultura e comunicazione 5 (5): 15–22.
- Spina, Stefania, Irene Fioravanti, Luciana Forti, Valentino Santucci, Angela Scerra, e Fabio Zanda. 2022. «Il corpus CELI: una nuova risorsa per studiare l'acquisizione dell'italiano L2». Italiano LinguaDue 14 (1): 116–38. https://doi.org/10.54103/2037-3597/18161.

Bonus / backup slides

Bonus slides: un esempio di data-driven learning

Come aumentare la competenza sociolinguistica nell'uso dei connettivi nella classe di italiano L2?

Partire dai bisogni linguistici

Bienati e Frey (in stampa):

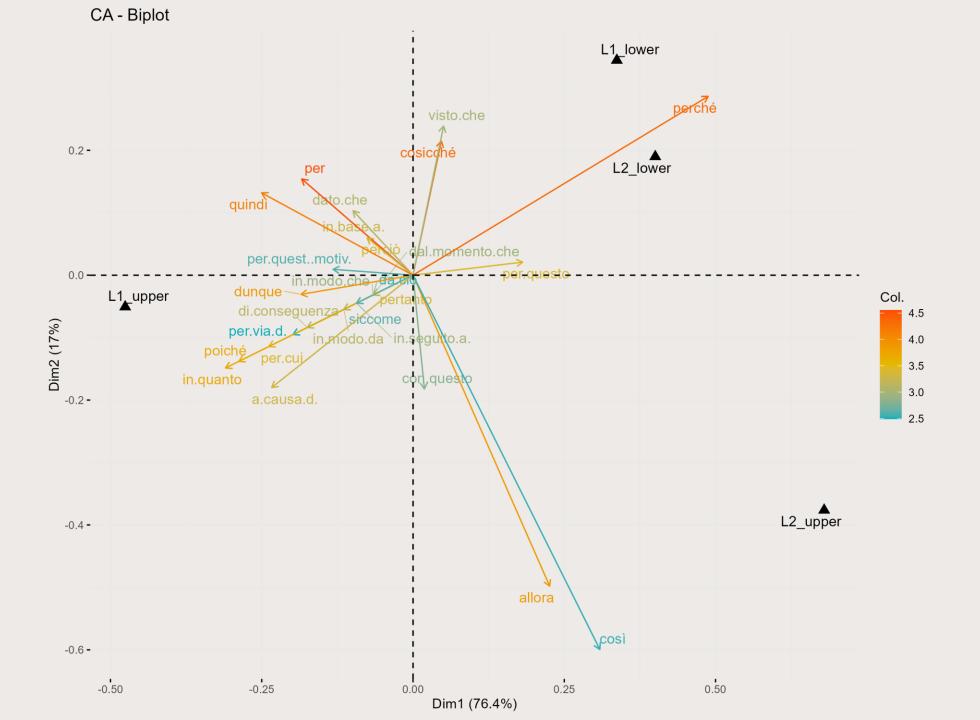
- Study design: confronto tra studenti italofoni in classi di italiano L1 e studenti tedescofoni in classi di italiano L2 alle medie e alle superiori.
- Risultati: alle superiori (quarto anno), sussistono differenze sostanziali nell'uso di connettivi causali tra i due gruppi, non tanto rispetto al numero di connettivi utilizzati in ciascun testo, quanto rispetto al tipo di connettivi utilizzati (maggiore ricercatezza lessicale e combinazioni di connettivi comuni/non comuni).

Connettivi usati dagli apprendenti di ITA L2:

A causa di	Per questo
Allora	Perché
Con questo	Quindi
Così	Visto che

Connettivi usati dagli apprendenti di ITA LI

A causa di	In base a	Per via di
Allora	In modo che	Perché
Con questo	In modo da	Perciò
Così	In quanto	Pertanto
Da ciò	In seguito a	Poiché
Dal momento che	Per	Quindi
Dato che	Per cui	Siccome
Di conseguenza	Per questo motivo	Visto che
Dunque	Per questo	



Definire il costrutto: la competenza sociolinguistica

"Possiamo definire la competenza sociolinguistica come la capacità procedurale non solo di interpretare il valore sociale delle scelte linguistiche compiute da altri parlanti, nativi e non, ma pure di compiere tali scelte in autonomia e in modo adeguato e appropriato (appropriatezza sociolinguistica) ai diversi temi, contesti, cotesti, interlocutori, e agli obiettivi dell'evento comunicativo" (Santipolo, 2014: 15)

Nella letteratura anglofona (es. Biber e Conrad, 2009), quando ci si riferisce in modo specifico alla competenza diafasica si parla di register knowledge o register awareness.

Un bel progetto della Humboldt-Universität sul tema: https://sfb1412.hu-berlin.de/

https://sfb1412.hu-berlin.de/projects/c04/

Rendere operativo il costrutto: ad es., i register scores

Table 2Calculating register score for the noun *analysis*.

	Academic	Fiction	Magazine	News	Summed frequency
Normed frequency	561.11	12.87	54.32	47.13	561.11 + 12.87 + 54.32 + 47.13 = 675.43
Register score	561.11/675.43 = 0.83	12.87/675.43 = 0.02	54.32/675.43 = .08	41.13/675.43 = .07	

"our measure of appropriateness is based on [...] the frequency per million words of 100,000 word forms in each of the five registers in the Corpus of Contemporary American English (Davies, 2008): spoken, academic, fiction, magazine and newspaper. [...] These frequency counts were lemmatized [...] and converted into register scores. Register scores represented the relative proportion of normalized occurrences of each word found in each register. [...] this was calculated by summing the normalized frequencies of the word across the four subcorpora then separately dividing the frequency for each register by that total. This yielded four numbers, summing to 1, which represented the relative proportion of occurrences found in each register. Words with register scores of close to .25 in all four registers (e.g. the) were evenly distributed, while scores above (or below) .25 in a given register showed that the word was skewed towards (or away from) that register (e.g. analysis, which is skewed towards the academic register and away from all other registers" (Durrant e Durrant, 2022: 51)

Un esempio di dashboard interattiva

	poiché		allora	
subcorpus	occorrenze		7104	
PROSA ACCADEMICA	4602		2782	
EPHEMERA: blogs, websites, etc.	1006		31706	
LETTERATURA	3001		1182	
PROSA GIURIDICO-AMMINISTRATIVA	2128		5769	
MISCELLANEA	2472		17365	
STAMPA	3175		302	
CONVERSAZIONE LIBERA	0		181	
ESAMI	3		284	
INTERVISTE SEMI STRUTTURATE	2		518	
LEZIONI	3		286	
RICEVIMENTI	0	_		

Puoi provare la dashboard direttamente su:

https://tinyurl.com/demobolo2024

foglio register_awareness